

Formulario para la Presentación de Proyecto

Máster en Inteligencia Artificial — Facultad de Ingeniería, Universidad ORT Uruguay

Versión 1 - borrador · Setiembre 2026

1. Identificación del proyecto

1.1 Nombre del proyecto

Pronóstico calibrado de entrega agéntica - sistema de pronóstico probabilístico y evaluación de calibración para software desarrollado con agentes de IA.

1.2 Estudiantes

Joaquín Guerra - 307854 - joacoguerrae@gmail.com

Germán Pazos - 242016 - germanpazos99@gmail.com

Ramiro Sanes - 368397 - ramirosanes@gmail.com

2. Resumen

El desarrollo de software ejecutado por agentes de IA genera, por primera vez, telemetría completa y automática del proceso de entrega: qué tarea se ejecutó, cuántas iteraciones requirió, cuándo intervino una persona y cuánto demoró cada decisión. Ese registro habilita una pregunta con valor comercial directo y sin respuesta publicada: ¿puede pronosticarse de forma probabilística y calibrada la entrega de un proyecto desarrollado con agentes?

El proyecto propone construir un producto de software que responda esa pregunta sobre datos reales: un sistema que ingiere telemetría de entrega agéntica, produce la distribución de probabilidad de la fecha de finalización de un proyecto (y, si los datos lo registran, de las horas de intervención humana requeridas), y genera automáticamente su propio boletín de calibración: un reporte que cuantifica cuánto puede confiarse en cada pronóstico emitido. La validación se realizará sobre la telemetría histórica de proyectos reales de la empresa Rootstrap, que desarrolla software mediante un sistema de agentes en producción y manifestó disposición a facilitar los datos. El diseño contempla una fuente de datos pública alternativa como mitigación, y un alcance en dos niveles (comprometido y deseable) acorde a la dedicación parcial del equipo durante seis meses.

3. Descripción del proyecto

3.1 Objetivos

Objetivo general. Construir y validar empíricamente un sistema de pronóstico probabilístico para proyectos de software desarrollados con agentes de IA, cuyo diferencial sea reportar la calidad de su propia calibración.

Objetivos específicos:

- **OE1.** Definir un esquema canónico para telemetría de entrega agéntica (tareas, duraciones, iteraciones de corrección, escalaciones a humanos, versión del proceso) e implementar su ingesta desde al menos una fuente real.
- **OE2.** Implementar un motor de pronóstico que, a partir de las distribuciones históricas por categoría de tarea y del grafo de dependencias del proyecto, produzca la distribución de probabilidad de su fecha de finalización (cuantiles P50/P80/P95). La selección del enfoque de estimación se fundamentará en una revisión de las alternativas aplicables.

- **OE3.** Construir una capa de evaluación automática de los pronósticos: backtesting con origen móvil y métricas estándar de la literatura de pronóstico probabilístico, tales como cobertura de cuantiles, PIT y CRPS.
- **OE4.** Comparar el desempeño del modelo contra al menos dos baselines simples pre-especificados (pronóstico por conteo de tareas y priors por categoría sin aprendizaje), para cuantificar qué aporta cada capa de complejidad.
- **OE5.** Estudiar empíricamente al menos una de dos preguntas abiertas que condicionan la validez del pronóstico: (a) la confiabilidad entre evaluadores del etiquetado de categorías de tarea; (b) cuánta historia conviene usar cuando el proceso de entrega cambia entre versiones (ventanas móviles y ponderación por recencia).

El alcance se formula abierto en OE5 y en los componentes internos del modelo: la elección fina (qué pregunta priorizar, qué variables incluir en el modelo) se ajustará a lo que el volumen y la calidad de los datos sostengan, con un punto de control en diciembre de 2026.

3.2 Resultados esperados

Resultados comprometidos:

- **R1.** Esquema canónico de telemetría y pipeline de ingesta funcionando sobre datos reales.
- **R2.** Motor de pronóstico (v1) operativo, con salida de distribuciones y cuantiles.
- **R3.** Boletín de calibración generado automáticamente sobre el histórico disponible (backtesting con origen móvil).
- **R4.** Comparación cuantitativa contra al menos dos baselines, con diseño congelado antes de ver los resultados.
- **R5.** Informe final con los hallazgos, cualquiera sea su dirección.

Resultados deseables (sujetos a disponibilidad de datos y avance):

- **R6.** Distribución de horas de intervención humana como segunda variable pronosticada.
- **R7.** El segundo estudio empírico de OE5 (el no priorizado).
- **R8.** Proyección viva sobre un proyecto en curso (re-pronóstico a medida que se completan tareas).

Nota metodológica: un resultado de calibración pobre, o el hallazgo de que los baselines simples igualan al modelo completo, constituye un resultado reportable y valioso del proyecto, no un fracaso. El diseño busca conclusiones informativas cualquiera sea el resultado.

3.3 Características tecnológicas

- Lenguaje y stack: Python (pandas, NumPy, SciPy, statsmodels, scikit-learn); motor de pronóstico de desarrollo propio; métricas de pronóstico con librerías estándar o implementación directa (CRPS, PIT, pérdida pinball).
- La selección de las familias de modelos a emplear se realizará durante el proyecto, a partir de una revisión de la literatura y considerando dos restricciones del problema: el volumen de datos disponible y el requisito de interpretabilidad del producto, dado que el sistema debe poder explicar el origen de cada pronóstico emitido.
- Visualización y reporte: matplotlib/Plotly; generación automática del boletín de calibración como reporte reproducible.
- Datos: export anonimizado de telemetría de ~10 proyectos históricos de Rootstrap, bajo acuerdo escrito. Fuente pública alternativa: dataset AIDev de agentes de código sobre GitHub.
- La unidad primaria de análisis es la tarea/capability, no el proyecto ($n \approx 10$), lo que hace viable la validación estadística con el volumen disponible.

- Gestión: repositorio Git, experimentos versionados, diseño de evaluación pre-registrado internamente antes de correr comparaciones.
- No se procesan datos personales ni información identificable de clientes; no se requiere comité de ética.

4. Recursos requeridos

- Acceso a la telemetría histórica de Rootstrap (export anonimizado) y un interlocutor técnico designado por la empresa, formalizados en un acuerdo escrito que incluya la autorización a publicar resultados, incluidos resultados desfavorables.
- Cómputo estándar (equipos personales; no se requiere GPU ni servicios pagos para el núcleo del proyecto).
- Para el estudio de confiabilidad de etiquetado: 2–3 personas etiquetando a ciegas una muestra de tareas (el propio equipo y/o personal de Rootstrap).
- Tutoría académica de la cátedra y, de confirmarse, referencia técnica externa de Rootstrap.

5. Plan de trabajo

Fase / período	Actividades principales	Entregable / hito
F0 · Set 2026	Acuerdo escrito con Rootstrap; export inicial de telemetría; verificación de campos disponibles (incl. si existen horas de intervención humana); presentación del anteproyecto.	Anteproyecto aprobado; datos en mano.
F1 · Oct 2026	Esquema canónico y pipeline de ingesta; análisis exploratorio; inicio del etiquetado a ciegas si el histórico no tiene categorías ex ante.	Dataset canónico versionado.
F2 · Nov 2026	Revisión de enfoques de pronóstico y Motor v1; implementación de baselines.	Primeros pronósticos sobre histórico.
F3 · Dic 2026	Primer boletín de calibración completo. Punto de control (go/no-go): ajuste de alcance según lo que los datos sostengan.	Report card v1; alcance revisado.
Ene 2027	Margen (exámenes y descanso); correcciones menores.	—
F4 · Feb 2027	Estudio empírico priorizado de OE5; torneo final contra baselines.	Resultados comparativos cerrados.
F5 · Mar 2027	Resultados deseables según avance; congelamiento de experimentos.	Experimentos cerrados.
F6 · Abr 2027	Escritura de la memoria y preparación de la defensa.	Entrega final.

6. Información adicional

6.1 Contexto y antecedentes

La estimación de esfuerzo de software cuenta con décadas de literatura (métodos empíricos, reference class forecasting, simulación de Montecarlo sobre datos históricos) que asume trabajo ejecutado por personas. En paralelo, la literatura reciente sobre agentes de desarrollo mide productividad, pero no calibración de pronósticos. El cruce, aplicar los protocolos de evaluación de

pronósticos probabilísticos a un proceso de entrega agéntica, no tiene, hasta donde se relevó, respuesta publicada. Rootstrap documentó el diseño de su método de estimación en un whitepaper interno (2026), aún sin validación empírica publicada: este proyecto construiría precisamente esa capa de validación, con la ventaja de credibilidad de realizarse por un equipo independiente.

6.2 Riesgos y mitigaciones

Riesgo	Mitigación
Dependencia de un tercero (Rootstrap) para los datos.	Acuerdo escrito temprano con interlocutor designado; esquema canónico que desacopla el sistema de la fuente; dataset público AIDev como alternativa para ejecutar el mismo diseño.
Volumen de datos insuficiente a nivel proyecto ($n \approx 10$).	La unidad primaria de análisis es la tarea/capability (n en cientos); el nivel proyecto se reporta como demostración (leave-one-project-out), no como validación estadística.
El histórico carece de categorías asignadas antes de la ejecución (riesgo de sesgo retrospectivo).	Etiquetado a ciegas (solo la especificación, nunca el resultado) por 2+ personas; el ejercicio habilita además el estudio de confiabilidad de OE5(a).
No estacionariedad: el proceso de entrega cambia entre versiones.	Segmentación por versión de proceso; estudio de ventanas de OE5(b); reporte del efecto en lugar de suponerlo nulo.
Dedicación parcial del equipo (6 meses, no exclusivos).	Alcance en dos niveles (comprometido/deseable); punto de control en diciembre con recorte explícito de alcance si es necesario

6.3 Consideraciones éticas

El proyecto no involucra datos personales, historias clínicas ni información de usuarios finales. La telemetría refiere a procesos de desarrollo de software; los datos de clientes de Rootstrap se reciben anonimizados según las condiciones del acuerdo. No se requiere aprobación del comité de ética.

Asimismo, el uso de activos de Rootstrap (datos, documentación, metodologías, software, arquitectura y procesos internos) se limita a fines académicos y de investigación dentro del alcance acordado por escrito con la empresa. La propiedad intelectual preexistente de Rootstrap, así como sus productos, plataformas y evoluciones futuras, permanece bajo su titularidad exclusiva, y la participación en el proyecto no otorga a los estudiantes derechos ni licencias sobre dicha tecnología. Los estudiantes conservan la autoría y los derechos sobre el trabajo académico producido, incluyendo análisis, modelos, conclusiones y resultados de investigación, conforme a la reglamentación de la Universidad ORT Uruguay. Rootstrap puede utilizar libremente esos resultados en sus productos, operaciones e investigación interna.

Estas condiciones se encuentran formalizadas en el acuerdo suscrito entre el equipo y Rootstrap.

7. Referencias bibliográficas

- [1] Miranda, P., Faria, J. P., Correia, F. F., Fares, A., Graça, R. y Mendes Moreira, J. (2021). An analysis of Monte Carlo simulations for forecasting software projects. *Proceedings of the 36th Annual ACM Symposium on Applied Computing (SAC '21)*, 1550–1558. <https://doi.org/10.1145/3412841.3442030>
- [2] Jørgensen, M. (2019). Evaluating probabilistic software development effort estimates: Maximizing informativeness subject to calibration. *Information and Software Technology*, 115, 93–96. <https://doi.org/10.1016/j.infsof.2019.08.006>

- [3] Gneiting, T., Balabdaoui, F. y Raftery, A. E. (2007). Probabilistic forecasts, calibration and sharpness. *Journal of the Royal Statistical Society: Series B*, 69(2), 243–268. <https://doi.org/10.1111/j.1467-9868.2007.00587.x>
- [4] Gneiting, T. y Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477), 359–378. <https://doi.org/10.1198/016214506000001437>
- [5] Sigweni, B., Shepperd, M. y Turchi, T. (2016). Realistic assessment of software effort estimation models. *Proceedings of the 20th International Conference on Evaluation and Assessment in Software Engineering (EASE 2016)*. <https://doi.org/10.1145/2915970.2916005>
- [6] Kumar, A., Bajpai, Y., Gulwani, S., Soares, G. y Murphy-Hill, E. (2025). Why AI agents still need you: Findings from developer-agent collaborations in the wild. *Proceedings of the IEEE/ACM International Conference on Automated Software Engineering (ASE 2025)*. arXiv:2506.12347
- [7] Dao, S. D. M., Huynh, T. K., Nguyen, L. P. Q., Pham, P. H., Tran, C. N., Nguyen, D. H. D. y Truong, B. T. (2026). Early-stage prediction of review effort in AI-generated pull requests. *MSR 2026 Mining Challenge*. arXiv:2601.00753
- [8] Li, H., Zhang, H. y Hassan, A. E. (2026). AIDev: Studying AI coding agents on GitHub. *Proceedings of the 23rd International Conference on Mining Software Repositories (MSR 2026)*. arXiv:2602.09185
- [9] Rootstrap (2026). *Estimations: about to be solved — Data-backed, semi-deterministic software estimation on a delivery system*. Whitepaper interno. [Fuente primaria del socio externo; citación sujeta a autorización.]
- [10] Jørgensen, M. y Sjøberg, D. I. K. (2003). An effort prediction interval approach based on the empirical distribution of previous estimation accuracy. *Information and Software Technology*, 45(3), 123–136. [https://doi.org/10.1016/S0950-5849\(02\)00188-X](https://doi.org/10.1016/S0950-5849(02)00188-X)
- [11] Jørgensen, M., Teigen, K. H. y Moløkken, K. (2004). Better sure than safe? Over-confidence in judgement based software development effort prediction intervals. *Journal of Systems and Software*, 70(1–2), 79–93. [https://doi.org/10.1016/S0164-1212\(02\)00160-7](https://doi.org/10.1016/S0164-1212(02)00160-7)
- [12] Batselier, J. y Vanhoucke, M. (2016). Practical application and empirical evaluation of reference class forecasting for project management. *Project Management Journal*, 47(5), 36–51. <https://doi.org/10.1177/875697281604700504>
- [13] Lokan, C. y Mendes, E. (2017). Investigating the use of moving windows to improve software effort prediction: A replicated study. *Empirical Software Engineering*, 22(2), 716–767. <https://doi.org/10.1007/s10664-016-9446-4>
- [14] Amasaki, S. y Lokan, C. (2015). On the effectiveness of weighted moving windows: Experiment on linear regression based software effort estimation. *Journal of Software: Evolution and Process*, 27(7), 488–507. <https://doi.org/10.1002/smr.1672>
- [15] Lokan, C. y Mendes, E. (2009). Applying moving windows to software effort estimation. *Proceedings of the 3rd International Symposium on Empirical Software Engineering and Measurement (ESEM 2009)*, 111–122. <https://doi.org/10.1109/ESEM.2009.5316019>
- [16] Flyvbjerg, B. (2006). From Nobel Prize to project management: Getting risks right. *Project Management Journal*, 37(3), 5–15. <https://doi.org/10.1177/875697280603700302>

[17] Vacanti, D. S. (2015). *Actionable Agile Metrics for Predictability: An Introduction*. ActionableAgile Press. ISBN 978-0-9864363-3-8